

Centinela de la Medida

Detección temprana de medidores con medida no confiable

Informe técnico-ético · Redes Neuronales — Deep Learning · Maestría en Ciencia de Datos, Universidad Santo Tomás
Grupo: Juan Manuel Gómez · Camilo Andrés Martínez · Sergio Beltrán

En una frase. Construimos una primera versión de un sistema que revisa el historial de consumo de cada usuario y señala a quiénes conviene inspeccionar primero, porque su medida podría no ser confiable. Funciona como un *filtro de priorización*: no acusa a nadie, ordena el trabajo de campo.

1. El problema, en términos del negocio

Una distribuidora de energía pierde ingresos cuando un medidor deja de registrar bien el consumo real: puede estar frenado, intervenido o con una conexión irregular. Hoy, decidir a quién inspeccionar se hace de forma manual, y cada visita cuesta tiempo y dinero. El sistema responde una pregunta concreta: **de todos los usuarios, ¿por cuáles conviene empezar a revisar?**

2. Qué hicimos, sin tecnicismos

Partimos de un registro real y anonimizado de **46.929 usuarios** con su consumo mensual durante **50 meses**. Apartamos a unos 5.300 usuarios inactivos (predios desocupados o cuentas suspendidas), que no son anomalías de medida. Sobre los **41.635 usuarios activos**, una red neuronal aprende a reconocer el perfil de una medida sospechosa: una **caída fuerte y sostenida del consumo** frente a lo que ese usuario gastaba normalmente, junto con otras señales del comportamiento histórico.

3. Qué tan bien funciona

0.95



AUC — capacidad de ordenar por riesgo
(0.5 sería puro azar)

0.64

F1-Score de la clase anómala
(supera el mínimo de 0.60)

72 %

de las anomalías reales detectadas (umbral 0.5)



Curva ROC: el sistema está muy por encima del azar.

El **AUC de 0.95** indica que el sistema **ordena muy bien a los usuarios por riesgo** —justo lo que necesita una lista de priorización— y que está lejísimos de «lanzar una moneda». El **F1 de 0.64** confirma un equilibrio sano entre detectar anomalías y no llenar de falsas alarmas al equipo de campo.

4. La empresa decide cuán exigente es el filtro

Umbral	F1	Anomalías detectadas	Inspecciones que genera	Falsas alarmas
Amplio (0.40)	0.61	79 %	678	343
Equilibrado (0.50)	0.64	72 %	535	230
Estricto (0.60)	0.64	65 %	430	158

El umbral fija cuántas inspecciones se ordenan al mes; es una **decisión de capacidad operativa del cliente**, informada por el sistema, no un parámetro fijo del código.

5. La dimensión ética: ¿qué error es peor?

Siguiendo el **Marco Ético para la IA en Colombia** (Minciencias, 2021), cada error afecta a personas distintas:

No detectar una anomalía real

Energía no facturada cuyo costo se traslada a todos los usuarios vía tarifa. Es el error que más quiere evitar la empresa.

Inspeccionar a un usuario honesto

Costo operativo y molestia/estigmatización de quien no hizo nada. Hay que vigilar que estas alertas no recaigan de forma desproporcionada sobre zonas o estratos vulnerables.

El sistema **no decide solo**: entrega una lista priorizada y la empresa elige el umbral. Y como la regla que define «anomalía» es una aproximación, el compromiso es **validarla contra las actas de inspección reales** antes de operar: solo el resultado de campo dice la verdad.

6. Recomendación al cliente

El sistema está listo como **herramienta de priorización en piloto**, no como veredicto automático. Recomendamos: (1) empezar con umbral estricto para que las primeras inspecciones tengan alta tasa de acierto y generen confianza; (2) registrar el resultado de cada visita para validar y mejorar el modelo; (3) avanzar a la Fase 2 con la fotografía del medidor, que permitirá pasar de «sospechar» a «confirmar».

Documento académico. Información tratada de forma anonimizada conforme a la Ley 1581 de 2012. Elaborado con apoyo de IA generativa, cuyo uso y verificación se documentan en la Bitácora de IA adjunta.