

Propuesta de Datos — Proyecto Centinela · Fase 1

«Centinela de la Medida»

Redes Neuronales — Deep Learning · Maestría en Ciencia de Datos · Universidad Santo Tomás

Integrantes: Juan Manuel Gómez · Camilo Andrés Martínez · Sergio Beltrán

1. Problema y cliente

Una empresa de servicios públicos de distribución de energía eléctrica necesita anticipar qué medidores de su mercado regulado presentan **medida no confiable o posible anomalía** (manipulación del medidor, conexión irregular, medidor frenado o submedición), que se manifiesta como una caída sostenida e injustificada del consumo registrado. Hoy la revisión del parque de medida se prioriza de forma reactiva y manual. Una alerta temprana que ordene por riesgo a los usuarios candidatos permitiría **priorizar las visitas de inspección en campo** y reducir la energía no facturada asociada a estas irregularidades.

Cliente. El área comercial de la empresa (gestión y reducción de pérdidas de energía), que recibe del modelo una lista priorizada de medidores a inspeccionar y decide, según su capacidad operativa, cuántas órdenes emitir.

2. Las dos modalidades

Modalidad temporal. Serie mensual del consumo facturado (kWh) por usuario (NIU), enero 2022 – febrero 2026 (50 periodos), con su transformador y circuito asociados. Es la modalidad que se aplanan a tabla en esta Fase 1.

Modalidad de imagen (Fase 2). Registro fotográfico de las actas de revisión y de las evidencias de lectura (estado del medidor: normal / ilegible o deteriorado / intervenido o dañado), sujeto a autorización institucional. Como contingencia se contemplan datasets académicos públicos de imágenes de medidores (laboratorio VRI–UFPR / Copel-AMR, licencia académica). En la Fase 2, la serie completa alimentará una red recurrente (LSTM/GRU) y las imágenes una CNN, con clave de alineación por NIU y periodo cuando se disponga de las fotos institucionales, o agregada por tipo de medidor en el escenario de contingencia.

3. Qué se aplanan en la Fase 1

La serie temporal de consumo se resume a una **tabla de características por usuario**: estadísticos del perfil histórico (mediana y desviación del consumo, coeficiente de variación), descriptores de la caída reciente (razón entre el consumo de los últimos 6 meses y la base histórica, número de meses recientes en cero), rezagos y descriptores del contexto (consumo relativo frente al promedio de su transformador y circuito). La etiqueta se construye sobre el comportamiento posterior, de modo que el modelo aprenda a anticipar la anomalía, no a describirla.

4. Fuentes (con enlace y licencia)

Modalidad	Fuente	Contenido	Acceso / licencia
Temporal	Sistema comercial de la empresa (extracto anonimizado de consumos por usuario)	Consumo mensual (kWh) de 46.929 usuarios × 50 meses, con transformador y circuito	Datos institucionales; uso académico bajo autorización y seudonimización (Ley 1581/2012)
Imagen (F2)	Actas de revisión / evidencias de lectura de la empresa	Fotografías del estado del medidor, con NIU y fecha	Institucional, bajo autorización
Imagen (F2, contingencia)	VRI–UFPR / Copel-AMR	12.500 imágenes de medidores en campo, parte de ellas ilegibles o defectuosas	Licencia académica no comercial (acuerdo firmado por la institución)

5. La etiqueta y por qué NO es un reto resuelto

No existe un archivo con la respuesta: la base de datos contiene el consumo, no una columna de «fraude». La etiqueta **se construye** a partir de la propia serie, en dos pasos honestos. Primero se excluyen del universo los usuarios **no analizables** (5.292 NIUs con la mitad o más del periodo en cero: predios desocupados, suspensiones o cuentas inactivas, que no son anomalías de medida y contaminarían el aprendizaje), quedando 41.637 usuarios. Sobre ellos se marca como **posible anomalía** a quien presenta una caída sostenida del consumo por debajo del 40 % de su base histórica, o varios meses recientes en cero teniendo historia de consumo: 3.001 usuarios (7,2 %), una clase minoritaria realista.

Esta es una **etiqueta proxy**, y su limitación se declara explícitamente: una caída de consumo es coherente con una anomalía de medida, pero también puede deberse a una mudanza, a un cambio real de hábitos o a una situación económica. Por eso el proyecto contempla una **validación posterior contra las actas de inspección reales** de la empresa (Camino de mejora): cuando se disponga del listado de NIUs con resultado de revisión verificado, se contrastará la etiqueta proxy con la realidad de campo, elevando la calidad del modelo y de la evaluación. No proviene de Kaggle ni de sus espejos; la fuente es un extracto institucional inédito, sin cuadernos públicos que resuelvan esta combinación.

6. Objetivos preliminares

General. Construir una línea base con un perceptrón multicapa (MLP) que, a partir del perfil de consumo de un usuario, estime la probabilidad de que su medida sea anómala, para priorizar las inspecciones en campo.

Específicos:

1. Explorar y depurar la serie de consumo, separando los usuarios no analizables y caracterizando el desbalance de la clase de interés.
2. Definir y justificar la etiqueta proxy de anomalía de medida y el conjunto de características derivadas del consumo.
3. Entrenar y regularizar un MLP de al menos dos capas ocultas, evaluándolo con métricas adecuadas al desbalance (matriz de confusión, recall y precisión de la clase anómala).
4. Analizar los errores en términos del costo para el cliente (falsos negativos frente a falsos positivos) bajo un marco ético, y dejar planteada la validación con actas reales y la evolución multimodal de la Fase 2.

7. Riesgos éticos

Un falso positivo genera una visita de inspección injustificada a un usuario honesto, con costo operativo y posible estigmatización; conviene vigilar que el modelo no concentre sus alertas en zonas o estratos específicos, por equidad (Marco Ético para la IA en Colombia, Minciencias, 2021). **Un falso negativo** deja sin detectar energía no facturada, cuyo costo se traslada al conjunto de usuarios. La elección del umbral de alerta —cuántas inspecciones ordenar— es una decisión del cliente, informada por el modelo, no un parámetro fijado en el código. Toda la información se trata de forma seudonimizada, conforme a la Ley 1581 de 2012.